

République Algérienne Démocratique et Populaire
Ministère de l'Enseignement Supérieur et de la Recherche Scientifique
Université des Sciences et de la Technologie Houari Boumediene



Faculté de Mathématiques

Département de Probabilité/Statistiques

TP

Estimation Non Parametrique

Etudiante:

BELHADDAD Magedouda Samia

Date : Mars 2023

1 . Estimation Non Parametrique des la distribution Jointe de deux variables aleatoires continues :

Dans le cas de l'estimation de la densité conjointe de deux variables, X et Y, un estimateur de densité à noyau bivarié peut être utilisé.

Cela implique l'utilisation d'une fonction noyau bidimensionnelle pour lisser les données observées. La largeur de bande de la fonction noyau détermine le degré de lissage .

L'estimateur de densité à noyau de la densité conjointe de x et y peut être approximé par une somme de fonctions à noyau centrées sur chaque point de données (x_i, y_i) .

L'estimateur de densité de noyau de la PDF conjointe peut être écrit comme suit :

$$f(x,y) = \frac{1}{nh_x h_y} \sum_{i=1}^n K\left[\frac{x-x_i}{h_x}, \frac{y-y_i}{h_y}\right]$$

h_x et h_y est un paramètre de largeur de bande qui contrôle le lissage de la PDF estimée,

et $K(u,v)$ est une fonction noyau.

$K(u,v)$ peut etre un noyau gaussien, le noyau d'Epanechnikov ...

Une petite valeur de h donnera lieu à une estimation à haute variance qui s'ajuste étroitement aux données, tandis qu'une grande valeur de h donnera lieu à une estimation à faible variance qui est plus lisse mais peut s'ajuster insuffisamment aux données.

Le Noyau Gaussian bivariate :

$$K(u,v) = (1/2\pi) \exp(-(u^2 + v^2)/2)$$

Le Noyau Epanechnikov bivariate:

$$K(u,v) = (3/4) * (1 - (u^2 + v^2))$$

2 . Espérance de cet estimateur bivarié :

$$\begin{aligned} E(\hat{f}(x,y)) &= E\left(\frac{1}{nh_x h_y} \sum_{i=1}^n K\left(\frac{x-X_i}{h_x}, \frac{y-Y_i}{h_y}\right)\right) \\ &= \frac{1}{h_x h_y} E\left(K\left(\frac{x-X_1}{h_x}, \frac{y-Y_1}{h_y}\right)\right) \\ &= \frac{1}{h_x h_y} \iint K\left(\frac{x-\mu_x}{h_x}, \frac{y-\mu_y}{h_y}\right) f_{X_1, Y_1}(\mu_x, \mu_y) d\mu_x d\mu_y \\ \text{on pose } t_x &= \frac{x-\mu_x}{h_x} \text{ et } t_y = \frac{y-\mu_y}{h_y} \text{ et on obtient :} \\ E(\hat{f}(x,y)) &= \frac{1}{h_x h_y} \iint K(t_x, t_y) f_{X, Y}(x-h_x t_x, y-h_y t_y) h_x h_y dt_x dt_y \\ &= \iint K(t_x, t_y) f_{X, Y}(x-h_x t_x, y-h_y t_y) dt_x dt_y \end{aligned}$$

3 . Variance de l'estimateur

$$\begin{aligned} \text{Var}(\hat{f}(x,y)) &= \text{var}\left(\frac{1}{nh_x h_y} \sum_{i=1}^n K\left(\frac{x-X_i}{h_x}, \frac{y-Y_i}{h_y}\right)\right) \\ &= \frac{1}{nh_x^2 h_y^2} \text{var}\left(K\left(\frac{x-X_1}{h_x}, \frac{y-Y_1}{h_y}\right)\right) \\ &= \frac{1}{nh_x^2 h_y^2} \left[E\left(K^2\left(\frac{x-X_1}{h_x}, \frac{y-Y_1}{h_y}\right)\right) - E^2\left(K\left(\frac{x-X_1}{h_x}, \frac{y-Y_1}{h_y}\right)\right) \right] \end{aligned}$$

4 . Majoration de la variance :

• $\text{Var}(\hat{f}(x,y)) = O\left(\frac{1}{n^k h_x h_y}\right)$


et ceci si f :

- * bornée, deux fois continuellement différentiable
- * à dérivées partielles bornées
- * si $\iint K^e(t_x, t_y) dt_x dt_y$ fini
- * si $\iint |t_k| K^e(t_x, t_y) dt_x dt_y < +\infty : k=1,2$


5 . Application : Pour un Kernel Gaussien

Cas X et Y indépendantes de loi respective $N(0, 1)$ et $N(m, 1)$:

```
7  set.seed(1)
8  # Generate some x and y data
9  size =100
10 m=3
11 x <- rnorm(size,mean =0,sd=1)
12 y <- rnorm(size,mean =m,sd=1)
13 # Create dataframe
14 data <- data.frame(x, y )
15
16 # Estimate the joint density using kde2d
17 pdf <- kde2d(data$x, data$y)
18
19 # Plot the estimated density
20 image(pdf, xlab = "x", ylab = "y")
21 contour(pdf, add = TRUE)
22
23
```



Cas X et Y indépendantes $N(19, 4)$ et $N(3, 7)$ VS $N(56, 4)$ et $N(56, 17)$:



Cas (X, Y) vecteur gaussien de moyenne (m1 , m2) et de matrice de variance covariance telle que $\text{cov}(X, Y) = r$, $\text{var}(X) = 9$ et $\text{var}(Y) = 4$:

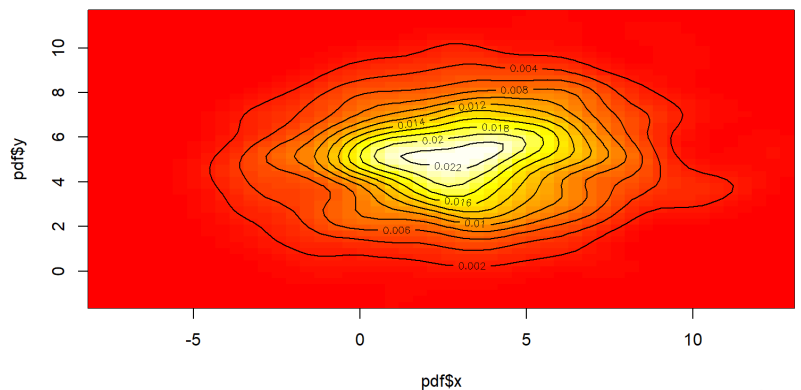
```
library(MASS)

# Set the mean vector and covariance matrix
mu <- c(3, 5)
sigma <- matrix(c(9, 0.5, 0.5, 4), nrow = 2)

# Generate random values of x and y
n <- 1000
data <- mvrnorm(n, mu, sigma)



# Compute the joint pdf using the density function
pdf <- kde2d(data[,1], data[,2], n = 50)

# Plot the joint pdf
image(pdf$x, pdf$y, pdf$z, col = heat.colors(50))
contour(pdf$x, pdf$y, pdf$z, add = TRUE)
```





Arthur W

Resultats pour un choix de bins :bins=5 vs bins=50





Pour h = 100 et h=15 :




Resultat pour d'autres valeurs de la matrice variance- covariance(x,y) :

sigma <- matrix(c(145, 77, 77, 56) mu <- c(33,15) et
mu <- c(0, 1) , sigma <- matrix(c(1, 0.5, 0.5, 2), nrow = 2)




X de loi exponentielle de paramètre α et la loi conditionnelle de Y sachant $X=x$ est la loi gamma de paramètre $(3, x + \alpha)$:


Alpha=5 :



Alpha=0.5

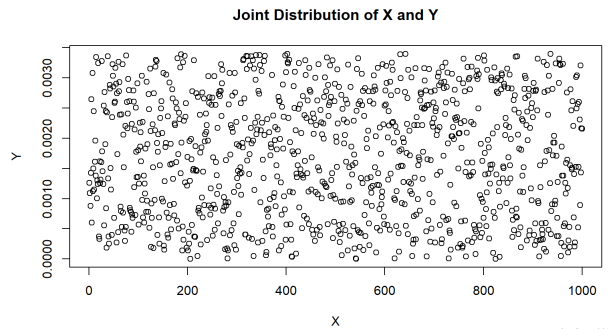


```
1 # Set the parameters
2 alpha <- 5
3
4 # Generate a random sample of X values
5 n <- 1000
6 x <- rexp(n, rate = alpha)
7
8 # Generate a random sample of Y values for each X value
9 y <- rep(0, n)
10 for (i in 1:n) {
11   y[i] <- rgamma(1, shape = alpha, rate = 1 / (x[i] + alpha)
12 }
13 # Combine X and Y into a dataset
14 data <- data.frame(x, y)
15
16 # Compute the joint pdf using the kdensity2d function
17 pdf <- kde2d(data$x, data$y, n = 50)
18
19 # Plot the joint pdf
20 image(pdf$x, pdf$y, pdf$z, col = heat.colors(50))
21 contour(pdf$x, pdf$y, pdf$z, add = TRUE)
```



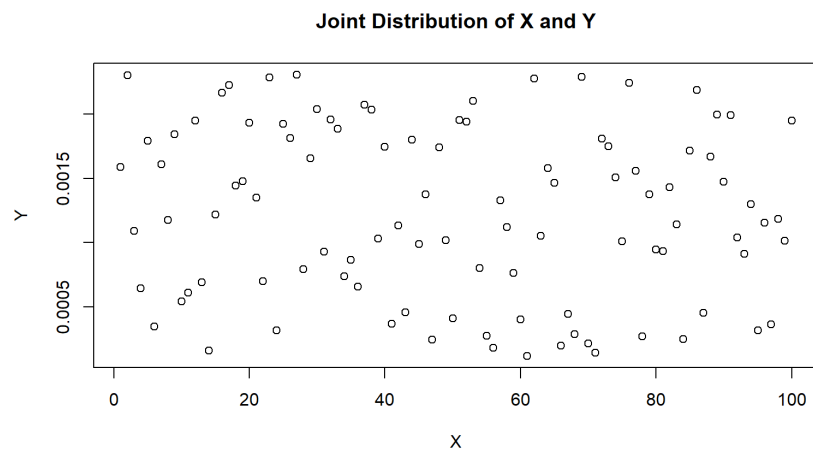
Densité theorique : Gaussian vector

```
# Actual  
# Vrai valeurs de xy  
xy_actual <- dmnorm(xy, mean = mu , sigma = sigma, log = FALSE)  
  
plot(xy_actual, type = "p", main = "Joint Distribution of X and Y", xlab = "X", ylab = "Y")
```



Densité theorique : Two Independent Normal RV

```
25 # Actual Data :  
26 x_actual <- dnorm(x, mean = 56, sd = 4)  
27 y_actual <- dnorm(y, mean = 56, sd = 17)  
28  
29 # Joint PDF  
30 joint_pdf <- x_actual * y_actual  
31  
32 # Reshape the PDF to a matrix and plot it as a heatmap  
33  
34  
35 plot(joint_pdf, type = "p", main = "Joint Distribution of X and Y", xlab = "X", ylab = "Y")  
36
```




Densité theorique : X : Normale :Y: Conditionelle Gamma

```
# Actual
x_actual <- dexp(x, rate = alpha)

y_actual <- rep(0, n)
for (i in 1:n) {
  y_actual[i] <- dgamma(y[i], shape = alpha, rate = 1 / (x_actual[i] + alpha))
}

joint_pdf <- x_actual* y_actual
plot(joint_pdf)
```



6. Calcul de la MSE :

```
> mean((xy_actual - xy)^2)
[1] 777.2714
~
```